

**資料中心熱監測、機櫃層級溫度預測
與功率感知利用之 AI/ML 模型技術報告**

Abstract

現代雲端資料中心的溫度預測相當困難，因為熱行為會受到工作負載、功率、冷卻、氣流、機櫃配置、設備異質性以及感測器位置等多個因素共同影響。當同一個機櫃包含不同型號伺服器、不同位置分布，以及不完整的感測覆蓋範圍時，傳統查表方法不足以支援即時管理。

本報告整理可用於資料中心熱監測與功率感知利用的 AI/ML 模型，並依照 CortexDC 已驗證的感測資料，提出保守的機櫃層級預測架構。模型調查涵蓋 XGBoost、LightGBM、GRU/LSTM、U-Net、隱式神經表示法(Implicit Neural Representation, INR)、數位孿生與強化學習。整體架構以「資料來源 → AI/ML 預測模型 → 熱風險判斷 → 功率感知決策 → 驗證與部署」作為主軸。

Keywords：資料中心熱管理，機櫃層級溫度預測，XGBoost，LightGBM，Redfish，PDU 監測，感測器配置，熱重建，功率監測

List of Abbreviations

Abbreviation	Definition
AI/ML	Artificial Intelligence / Machine Learning，人工智慧與機器學習
BMC	Baseboard Management Controller，主機板管理控制器
CPU	Central Processing Unit，中央處理器
GPU	Graphics Processing Unit，圖形處理器
PDU	Power Distribution Unit，配電單元
Redfish	伺服器管理與感測資料存取介面
XGBoost	Extreme Gradient Boosting，梯度提升決策樹模型
LightGBM	Light Gradient Boosting Machine，輕量化梯度提升模型

GRU	Gated Recurrent Unit，門控循環單元
LSTM	Long Short-Term Memory，長短期記憶網路
U-Net	具有編碼器與解碼器結構的卷積神經網路
INR	Implicit Neural Representation，隱式神經表示法
DQN	Deep Q-Network，深度 Q 網路
RL	Reinforcement Learning，強化學習
PUE	Power Usage Effectiveness，電源使用效率
CFD	Computational Fluid Dynamics，計算流體力學
CRAC	Computer Room Air Conditioner，電腦機房空調

目錄

內容

Abstract	2
List of Abbreviations.....	2
目錄.....	3
1 緒論.....	7
1.1 研究背景：資料中心熱管理與能源效率挑戰.....	7
1.3 報告目標與技術範圍.....	8

1.4 報告架構.....	8
2.熱與功率預測的 AI/ML 模型調查	8
2.1 結構化回歸模型：Baseline 與可解釋性	8
2.2 時序模型：短期溫度與功率趨勢預測.....	9
2.3 空間建模：機櫃鄰近關係與熱耦合分析	9
2.4 熱場重建：感測器不足下的溫度分布估計	9
2.5 最佳化與控制模型：從預測到決策.....	10
2.6 模型比較與本報告採用策略.....	10
3 系統架構與資料來源	10
3.1 資料中心熱管理系統架構.....	10
3.2 CortexDC 中已驗證的感測資料	11
3.3 感測資料分類：溫度、功率、負載、風扇與環境資料.....	12
3.4 資料粒度與時間解析度	13
3.5 資料品質議題：缺失值、異常值與同步問題.....	13
4 所提出的機櫃層級溫度與功率預測架構.....	13
4.1 問題形式化：輸入、輸出與預測時間範圍	14
4.2 特徵工程：負載、功率、溫度與空間關係特徵.....	15
4.3 預測目標：機櫃溫度、CPU/GPU 熱風險與功率趨勢	15

4.4 模型設計：Baseline 模型、時序模型與混合式模型	15
4.5 模型輸出與風險指標定義	15
5 功率感知的預防與決策機制	16
5.1 熱狀態映射與風險分級	16
5.2 CPU/GPU 過熱預防機制	16
5.3 功率感知的機櫃利用率管理	17
5.4 過載預防與工作負載調度建議	17
5.5 預測結果與管理策略的閉迴路流程	17
6 驗證策略、實作路線圖與開放議題	17
6.1 驗證策略：預測準確度、提前預警能力與誤報率	17
6.2 實驗設計：Baseline 比較、消融實驗與情境測試	17
6.3 實作路線圖：資料整備、模型訓練、部署與監控	18
6.4 數位孿生與強化學習之未來擴充	18
6.5 開放議題：資料不足、模型泛化、可解釋性與安全性	18
7 結論	19
7.1 技術總結	19
7.2 預期效益	19
7.3 未來發展方向	19

參考文獻.....	19
-----------	----

1 緒論

1.1 研究背景：資料中心熱管理與能源效率挑戰

隨著雲端運算、人工智慧（AI）及高效能運算需求快速成長，資料中心已成為現代數位服務的重要基礎設施。然而，資料中心同時也是高耗能系統，其中大部分 IT 設備所消耗的電能最終會轉換為熱能，進而增加冷卻系統的能源需求。若熱狀態無法被有效監測與管理，可能導致局部熱點（Hotspot）、設備可靠度下降、CPU/GPU 降頻以及冷卻資源浪費等問題。因此，如何在維持系統穩定運作的同時提升能源效率，已成為資料中心管理的重要課題。為解決上述問題，2023 年，Lin 等人提出了多種熱建模與熱管理方法，包括以物理模型為基礎的 White-box 方法、以資料驅動為核心的 Black-box 方法，以及結合兩者優點的 Gray-box 方法[1]。近年來，機器學習技術已逐漸應用於資料中心的溫度預測與熱管理。其中，2023 年，Nisce 等人利用 XGBoost 建立 CPU 與伺服器層級的熱預測模型，以使用率、溫度及能耗等結構化感測資料作為輸入，並在雲端伺服器溫度預測中獲得良好的預測準確度 [8]。2020 年 Ilager 等人比較多種機器學習模型於雲端主機溫度預測之效能，結果顯示 XGBoost 具有較佳的預測能力，因此將其應用於熱感知工作負載排程系統 [9]。此外，2022 年，Lin 等人針對氣冷式資料中心評估多種資料驅動熱預測模型，研究指出 XGBoost 與 LightGBM 在機櫃進氣溫度預測方面具有良好的效能與泛化能力 [10]。上述研究顯示，XGBoost 與 LightGBM 能有效處理資料中心的結構化感測資料，適合作為伺服器層級與機櫃層級溫度預測的基礎模型。然而，此類模型主要著重於數值預測，對於空間熱場重建、感測器不足情境及最佳化控制仍有其限制，因此仍需結合其他方法，以支援更完整的熱管理與預防決策

1.2 問題定義：溫度預測、熱風險預防與功率感知管理

本報告關注的核心問題，是如何利用已驗證的感測資料建立機櫃層級的溫度與功率預測，並將預測結果轉換成可執行的熱風險預防策略。這包含三個層次：第一，預測伺服器與機櫃在下一時間區間的溫度；第二，判斷 CPU/GPU 與機櫃是否具有過熱風險；第三，根據功率與熱餘裕提出機櫃利用率或工作負載調度建議。

1.3 報告目標與技術範圍

- 整理資料中心熱與功率預測相關的 AI/ML 模型，並說明各模型適合處理的資料型態與任務。
- 根據 CortexDC 已驗證的 Redfish、PDU、環境感測器與機櫃中繼資料，建立保守的機櫃層級預測架構。
- 將伺服器層級預測與機櫃層級預測分開，並加入空間特徵，例如機櫃 ID、伺服器位置、鄰近溫度與機櫃功率分布。
- 提出功率感知的預防與決策流程，但不宣稱已完成新的實驗結果或真實部署控制。

1.4 報告架構

本文其餘章節安排如下。第 2 章整理熱與功率預測的 AI/ML 模型；第 3 章系統架構與資料來源；第 4 章提出機櫃層級溫度與功率預測架構；第 5 章說明功率感知的預防與決策機制；第 6 章提出驗證策略、實作路線圖與開放議題；第 7 章總結本報告的技術重點與未來方向。

2. 熱與功率預測的 AI/ML 模型調查

2.1 結構化回歸模型：Baseline 與可解釋性

XGBoost 與 LightGBM 適合用於結構化感測資料，因為它們能處理非線性關係、混合尺度特徵與經過設計的表格型特徵。XGBoost，根據使用率、溫度與能量相關資料進行 CPU/伺服器層級熱預測，並在雲端伺服器溫度預測中回報了低預測誤差 [8]。Ilager et al. 比較了多種用於雲端主機溫度預測的機器學習模型，並在熱感知排程系統中使用 XGBoost 作為最強的預測器 [9]。Lin et al. 評估了用於氣冷式資料中心熱預測的資料驅動模型，並發現 XGBoost 與 LightGBM 在穩態機櫃進氣溫度預測上表現良好 [10]。

對於本報告而言，這類模型可作為第一階段 baseline，用於伺服器層級與機櫃層級溫度預測。其優點是訓練成本相對低、特徵重要性容易解釋，且適合處理功率、溫度、風扇、PDU 與機櫃中繼資料等結構化欄位，但限制是無法單獨重建完整熱場，也無法直接產生最佳控制行動。

2.2 時序模型：短期溫度與功率趨勢預測

資料中心熱行為具有延遲性。工作負載與功率可能快速變化，但溫度因熱傳導與冷卻慣性而較慢反應。2017 年 Zhang 等人顯示機器學習可用於預測元件溫度，以支援執行期熱管理，並引導熱感知任務配置 [2]。2023 年 Wang 等人提出一個兩階段自我修復模型，先預測 CPU 使用率，再利用 CPU、風扇、進氣/排氣溫度、CRAC 溫度與鄰近伺服器溫度資料來預測未來伺服器進氣溫度 [5]。2020 年 ThermoSim 也展示循環神經網路如何支援雲端環境中的熱感知模擬與資源管理 [11]。GRU/LSTM 可用於學習歷史功率、溫度與風扇變化對未來溫度的影響。若資料取樣頻率不足，簡單延遲特徵與趨勢特徵可能已能形成可用的基準，若資料長期且穩定，才建議導入更複雜的循環神經網路 (Recurrent Neural Network, RNN)。

2.3 空間建模：機櫃鄰近關係與熱耦合分析

機櫃層級預測必須具有空間感知。伺服器 U 位置大小、伺服器位置、機櫃位置、垂直區域、伺服器分布與氣流路徑都會改變相同功率所造成的熱效應。2018 年 Sano 等人顯示，詳細的 CFD 建模可以提升資料中心溫度分布預測的準確度，因為氣流與機櫃縫隙會影響進氣溫度 [3]。2012 年 Wang 等人指出，感測器配置會影響熱伺服器偵測，而由 CFD 引導的配置方式比均勻配置更能偵測過熱 [4]。2023 年 Andersson 等人研究了具有不確定性感知的環境感測器配置，並使用卷積式高斯神經過程；雖然其應用場景並非資料中心，但其概念可用於判斷新增量測位置如何降低不確定性 [7]。因此，模型不應只使用伺服器本身感測，也應加入機櫃 ID、伺服器位置、伺服器 U 位置大小、上/中/下區域功率、鄰近伺服器或鄰近機櫃溫度等特徵。

2.4 熱場重建：感測器不足下的溫度分布估計

當感測器稀疏時，單一溫度預測值不足以呈現機櫃或機房的完整熱狀態。U-Net、物理資訊神經網路(physics-informed neural network, PINN)與 INR 可從有限觀測推估完整熱圖。2025 年 Yuan 等人提出一個數位孿生原型，使用感測器資料、伺服器功率與 CRAC 溫度作為輸入；U-Net 代理模型用於重建 2D 溫度場，而 DQN 決策代理則根據 PUE 降低、溫度均勻性與熱點抑制來建議冷卻決策 [6]。這使數位孿生不只是視覺化工具，也成為連接預測與安全最佳化的重要橋梁。2024 年 Sabathiel 等人使用神經網路架構，從稀疏量測重建未知材料組成系統中的穩態溫度場 [12]。2022 年 Peng 等人使用基於分區建模的自適應 U-Net 與 MLP，從有限觀測點重建溫度場 [13]。2024 年 Luo 等人則使用隱

式神經表示法，從稀疏觀測重建連續場 [14]。不過，這類方法通常需要感測器座標、空間網格與可作為訓練標籤的熱圖資料，因此較適合作為第二階段延伸。

2.5 最佳化與控制模型：從預測到決策

預測只有在連接到監測、警告或控制決策時才具有操作價值。2014 年 Zapater 等人顯示，伺服器風扇控制應考慮漏電功率與風扇功率之間的取捨 [15]。2019 年 Chan 等人加入效能面向，指出冷卻風扇決策可能影響硬碟效能與應用程式延遲 [16]。2019 年 Ran 等人提出 DeepEE，這是一個強化學習架構，用於聯合最佳化資料中心能源效率中的工作排程與冷卻控制 [17]。最佳化與控制模型可用於工作負載排程、風扇控制、冷卻設定點調整與能源效率改善。不過，直接控制真實資料中心具有安全風險，因此應先在規則限制、模擬器或數位孿生環境中評估。

2.6 模型比較與本報告採用策略

模型類型	適合任務	本報告採用策略
XGBoost / LightGBM	結構化感測資料、baseline、可解釋性	第一階段主要模型
GRU / LSTM	短期趨勢、熱延遲、歷史序列	資料穩定後評估
空間特徵模型	機櫃 伺服器位置、鄰近關係、熱耦合	必須納入機櫃層級預測
U-Net / INR	稀疏感測器到完整熱場重建	第二階段延伸
數位孿生 / RL	行動評估、工作負載與冷卻最佳化	未來決策最佳化

3 系統架構與資料來源

3.1 資料中心熱管理系統架構

實體層包含伺服器、機櫃、PDU 與環境感測器。伺服器感測資料可透過 Redfish 從 BMC 收集，PDU 資料可依裝置能力透過 SNMP、Modbus TCP 或 Redfish 收集。

CortexDC/iBox 則負責儲存近期與歷史感測資料，並提供給特徵工程、預測模型與預防決策層使用。而圖 1 為本報告提出之資料中心熱管理整體系統概念架構，用以說明系統由資料蒐集、AI 預測、熱狀態分析至預防決策的完整流程。此架構著重於各功能模組之間的關係與資料流向。整體流程可分為四個階段：(1) 資料蒐集與前處理、(2) AI 預測模型、(3) 熱狀態分析與未來擴充，以及 (4) 預防決策與管理應用。首先，系統整合 Server/BMC、PDU、環境感測器及 Rack Metadata 等多種資料來源，經過資料蒐集、品質檢查、時序儲存及特徵工程後，建立可供 AI 模型使用之輸入特徵。接著，以 Server-Level 與 Rack-Level 預測模型估測未來溫度及熱風險，並可直接提供 Hotspot 與異常事件預警。進一步可結合熱場重建、數位孿生及強化學習等方法作為後續功能發展，最後將預測結果轉換為過熱預防、工作負載配置、冷卻控制及容量規劃等決策建議。




圖 1：資料中心熱管理整體架構

3.2 CortexDC 中已驗證的感測資料

CortexDC 為 Vossic Technology 所開發的資料中心基礎設施管理（Data Center Infrastructure Management, DCIM）平台，主要提供資料中心設備監控、能源管理、環境監測及資產管理等功能。平台整合 IT 設備與基礎設施的監測資訊，協助管理者即時掌握資料中心的運作狀態，提升設備可靠度與能源使用效率。CortexDC 可整合多種資料來源，包括伺服器管理介面（如 Redfish/BMC）、PDU、環境感測器（溫度、濕度、氣流等）以及機櫃相關資訊（Rack Metadata），將不同設備的感測資料集中管理，形成統一的監

控平台。系統亦提供資料蒐集、即時監測、歷史資料查詢、警告通知及視覺化儀表板等功能，方便管理者分析資料中心的運作情況。在本技術報告中，CortexDC 作為感測資料的主要來源。透過 CortexDC 所收集之伺服器功率、CPU/GPU 溫度、PDU 能耗、環境感測器及機櫃資訊，可建立 AI/ML 模型所需之輸入特徵，進一步進行溫度預測、熱風險分析及機櫃容量評估，並支援後續 Thermal Prevention 與 Power-aware Management 等應用。

由於實際資料中心可取得的遙測資訊受設備型號、管理介面及監測平台所限制，因此本報告以 CortexDC 平台實際提供之資料作為分析基礎，而不假設所有理想特徵皆可取得。CortexDC 整合多種資料來源，包括 Server/BMC Redfish、PDU 及 Rack Metadata。其中，Server/BMC Redfish 提供伺服器功率、溫度感測器、風扇轉速、由供應商（OEM）介面提供之 GPU 指標，以及設備健康狀態與電源狀態等遙測資訊 [18]；PDU 提供進線與出線電氣量測、總有效功率、累積有效電能、功率因數、環境感測器及歷史趨勢等電力監測資料 [19]；Rack Metadata 則包含機櫃中繼資料、伺服器 U-Position、Redfish 輪詢間隔（Polling Interval）、伺服器功率、進氣溫度及 CPU 溫度等設備資訊，部分欄位可能因設備差異而無法取得 [20]。上述資料共同構成本報告後續特徵工程、溫度預測、熱風險分析及預防決策之主要輸入。

3.3 感測資料分類：溫度、功率、負載、風扇與環境資料

資料分類	代表欄位	主要用途
溫度資料	CPU 溫度、GPU 溫度、進氣溫度、外部環境溫度、溫度閾值	伺服器層級溫度預測、機櫃最高溫度估計、熱點警告
功率資料	伺服器目前功率、平均功率、PDU 總有效功率、插座有效功率、功率因數、有效電能	作為熱源代理、機櫃功率聚合、過載與低利用率檢查
負載資料	CPU 使用率、記憶體使用率、網路流量、磁碟 I/O（若穩定可用）	描述工作負載強度；若資料不完整，僅列為選用特徵
風扇與冷卻資料	風扇 RPM、風扇狀態、風扇備援、CRAC 相關溫度	描述冷卻反應與風扇異常

	(若可用)	
環境與機櫃中繼資料	機櫃 ID、伺服器位置、伺服器 U 位置大小、伺服器放置順序、濕度、氣流	建立空間特徵與環境背景

3.4 資料粒度與時間解析度

本報告中的資料粒度可分為機櫃層級、伺服器層級、元件層級與 PDU 插座層級。不同資料粒度會影響模型能描述的熱行為範圍，例如機櫃層級資料適合描述整體熱風險，伺服器與 CPU/GPU 層級資料則適合判斷局部過熱風險。資料粒度也會影響模型可以預測的時間範圍。若 Redfish 收集間隔較長，例如數分鐘等級，則第一階段可使用移動平均、移動最大值、延遲值與變化率建立基準模型。若未來可取得更高頻率且穩定的歷史軌跡，則可進一步評估 GRU/LSTM 等時序模型。

3.5 資料品質議題：缺失值、異常值與同步問題

建立模型前應先檢查每個欄位的缺失率、單位一致性、時間戳同步、資產對應關係與異常值。若 CPU 使用率或 Node Exporter 指標在機櫃文件中經常為 N/A，則不應列為第一版模型的必要特徵。

4 所提出的機櫃層級溫度與功率預測架構

本章重點在於「如何預測」。整體架構包含資料來源、感測資料擷取、資料可用性過濾、特徵工程、伺服器層級與機櫃層級預測、模型輸出與風險指標。圖 2 進一步聚焦於預測與預防決策流程之模組化設計。整體流程可分為七個階段，依序包含資料來源（Data Sources）感測資料蒐集（Telemetry Acquisition）、資料可用性過濾（Availability Filter）、特徵工程（Feature Engineering）、溫度預測（Prediction）、熱狀態映射（Thermal-State Mapping）以及預防決策支援（Prevention Decision Support），形成由資料蒐集至決策建議的完整處理流程。首先，在資料來源階段，系統整合多種資料中心感測資訊，包括伺服器 Redfish/BMC 所提供的 CPU、GPU、功率、溫度與風扇等感測資料、PDU（Power Distribution Unit）的電壓、電流與耗能資訊、環境感測器量測資料，以及機櫃位置、伺服器 U-Position、設備配置等 Rack Metadata。這些資料共同構成後續模型分析的基礎。接著，於感測資料蒐集階段，系統透過 Redfish、PDU 與環境感測器介面收集即時資料，並完成時間戳記同步與資料格式標準化。為提升資料品質，資料可用性過濾

模組將移除缺失值、檢查量測單位及資料有效性，並保留可用欄位與缺失標記，以供後續分析使用。完成資料清理後，特徵工程模組進一步建立模型所需特徵，包括功率特徵（Power Features）、熱特徵（Thermal Features）、空間特徵（Spatial Features）以及時間特徵（Temporal Features），並分別產生伺服器層級與機櫃層級的特徵矩陣。在預測階段，系統分為兩條分析流程。Server-Level Prediction 以伺服器特徵為輸入，預測 CPU、GPU 或進氣溫度等熱風險。Rack-Level Prediction 則利用機櫃特徵估測平均溫度、最高溫度及 Hotspot 發生風險，兩者的預測結果將作為後續熱管理的重要依據。最後，預測結果結合機櫃空間資訊建立 Thermal-State Mapping，產生資料中心熱狀態分布與風險地圖，並輸入至 Prevention Decision Support 模組。此模組根據熱狀態、剩餘功率容量（Power Headroom）及預測結果，提供預警資訊、候選管理策略及機櫃利用率建議，未來亦可進一步結合數位孿生或強化學習等方法，支援更智慧化的熱管理與功率感知決策。




圖 2：預測與預防決策流程之模組化設計

4.1 問題形式化：輸入、輸出與預測時間範圍

假設機櫃 r 在時間 t 包含作用中的伺服器 $s \in S_r$ 。基準機櫃特徵向量可定義為：

$$x_{r,t} = [p_{r,t}, q_{r,t}, h_{r,t}, z_{r,t}, d_{r,t}]$$

其中 $p_{r,t}$ 表示功率特徵， $q_{r,t}$ 表示熱特徵， $h_{r,t}$ 表示健康狀態與風扇特徵， $z_{r,t}$ 表示空間機櫃特徵， $d_{r,t}$ 表示時間差分或延遲特徵。

基準機櫃層級預測問題可寫為：

$$\hat{y}_{r,t+\Delta} = f(x_{r,t})$$

其中 $\hat{y}_{r,t+\Delta}$ 可包含預測機櫃平均溫度、最高溫度、下一時間區間熱點風險或機櫃利用狀態。預測時間範圍 Δ 應與資料收集間隔及操作反應時間相匹配。

4.2 特徵工程：負載、功率、溫度與空間關係特徵

- 功率特徵：總機櫃功率、平均伺服器功率、最大伺服器功率、PDU 總有效功率、插座有效功率、有效電能與功率因數。
- 溫度特徵：平均 CPU 溫度、最大 CPU 溫度、平均進氣溫度、最大進氣溫度與外部環境溫度。
- 冷卻與健康特徵：風扇速度、風扇狀態、伺服器健康狀態、電源狀態，以及可用時的 GPU 溫度與功率。
- 空間特徵：機櫃 ID、伺服器位置、伺服器 U 位大小、上/中/下機櫃區域、加權伺服器位置、作用中伺服器數量、鄰近伺服器或鄰近機櫃溫度。
- 時間特徵：溫度變化率、功率變化率、移動平均、移動最大值，以及延遲的溫度與功率值。

4.3 預測目標：機櫃溫度、CPU/GPU 熱風險與功率趨勢

伺服器層級目標包含下一時刻 CPU 溫度、下一時刻進氣溫度、GPU 感測存在時的 GPU 過熱風險，以及個別伺服器熱點風險。機櫃層級目標包含機櫃平均溫度、機櫃最高溫度、下一區間機櫃溫度、熱點風險分數，以及機櫃功率利用狀態。

4.4 模型設計：Baseline 模型、時序模型與混合式模型

第一階段建議以 XGBoost/LightGBM 作為 baseline，因為目前已驗證資料主要為表格型感測資料。若歷史軌跡足夠穩定，可加入 GRU/LSTM 進行短期時序預測。混合式模型則可先由 baseline 模型處理結構化特徵，再加入延遲特徵、空間特徵或時序模型輸出，提升對熱延遲與空間熱耦合的描述能力。

4.5 模型輸出與風險指標定義

模型輸出不應只包含單一溫度值，也應轉換為可操作的風險指標。例如熱點風險分數可同時考慮預測最高溫度、溫度上升斜率、功率集中程度與熱餘裕。

- 正常：預測溫度與功率皆在安全範圍內，且溫度趨勢穩定。
- 警告：預測溫度尚未超過限制，但溫度斜率或區域功率集中度偏高。

- 危急：預測溫度接近或超過 CPU/GPU 或機櫃安全限制。
- 不穩定趨勢：短時間內溫度或功率變化劇烈，需要人工檢查或降低負載。

表 1 各階段預測與決策模型配置	
Stage	Model
Baseline	XGBoost / LightGBM
Time-series	GRU (Future)
Spatial	U-Net / INR (Future)
Decision	Rule-based
Optimization	RL (Future)

5 功率感知的預防與決策機制

本章根據第 4 章所建立之預測結果，進一步探討如何將模型輸出轉換為可執行之預防與決策策略。預防與決策機制會將模型輸出轉換成熱狀態分級、CPU/GPU 過熱預防、機櫃利用率管理、過載預防與工作負載調度建議。

5.1 熱狀態映射與風險分級

熱狀態映射的目的，是把原始感測資料與模型預測轉換成可判斷、可排序、可執行的風險狀態。建議同時建立機櫃區域圖、熱風險圖、工作負載狀態圖與數位孿生狀態圖。

- 機櫃區域圖：將伺服器功率、CPU 溫度、進氣溫度、風扇速度與伺服器狀態聚合到上、中、下區域。
- 熱風險圖：將預測溫度轉換為正常、警告、危急與不穩定趨勢。
- 工作負載狀態圖：將相似的功率與溫度模式分群，作為調度建議的依據。
- 數位孿生狀態圖：未來在空間資料足夠後，將稀疏感測與預測結果投影到熱場中。

5.2 CPU/GPU 過熱預防機制

CPU/GPU 過熱預防應採用主動方式，而不只是等待閾值警報。模型可在下一個時間區間溫度變得危險前提出警告。基準流程為：使用 XGBoost 或 LightGBM 估計下一區間 CPU/進氣溫度；結合風扇速度與功率趨勢；若 GPU 溫度與功率可用，則納入 GPU 風險判斷；當預測風險偏高時，建議降載、遷移、降頻或硬體檢查。

5.3 功率感知的機櫃利用率管理

機櫃利用率不應只由功率容量判斷。即使電氣容量仍有餘裕，若熱餘裕不足，也不應再接收額外工作負載。因此，建議建立聯合機櫃狀態指標，同時考慮功率容量、作中伺服器數量、預測最高溫度與熱點風險。

- 熱風險調整後的利用率：熱風險越高，可接受利用率越低。
- 區域功率不平衡：檢查上/中/下層功率，避免熱源過度集中。
- 伺服器貢獻排名：高功率且高預測溫度的伺服器應優先被考慮降載或遷移。
- 低利用但仍開機狀態：可作為整併或睡眠狀態建議候選。

5.4 過載預防與工作負載調度建議

過載預防可分為電氣過載與熱過載。電氣過載由 PDU 有效功率、插座電流與容量限制判斷；熱過載則由預測最高溫度、熱點風險與溫度上升趨勢判斷。工作負載調度建議應優先避開高風險機櫃，並將新增負載安排到功率與熱餘裕都足夠的機櫃。

5.5 預測結果與管理策略的閉迴路流程

閉迴路流程可分為六步驟：資料收集、資料清理與同步、模型預測、風險分級、管理策略建議、結果回饋與模型監控。在控制介面與安全限制尚未完整定義前，系統應先採用 shadow mode，也就是只提供行動建議而不直接控制實體設備。

6 驗證策略、實作路線圖與開放議題

6.1 驗證策略：預測準確度、提前預警能力與誤報率

第一個驗證步驟應先評估感測資料完整性，而不是直接評估模型準確率。每個欄位都應檢查缺失率、取樣間隔、單位一致性，以及是否能對應到正確的伺服器、插座、機櫃與伺服器位置。模型指標可包含 MAE、RMSE、最高溫度誤差、熱點分類 precision/recall、提前預警時間、誤報率與缺失資料穩健性。而 Ground Truth 是下一時間 Redfish 真正量到各感測資料的 Temperature。伺服器層級模型與機櫃層級模型應分開驗證，避免將局部預測效果誤認為整體機櫃效果。

6.2 實驗設計：Baseline 比較、消融實驗與情境測試

- Baseline 比較：與移動平均、線性回歸、Random Forest、XGBoost、LightGBM 與可用時序模型比較。

- 消融實驗：移除功率特徵、溫度延遲特徵、空間特徵或鄰近特徵，觀察預測誤差是否上升。
- 情境測試：測試高負載、冷卻異常、機櫃功率接近上限、單一區域功率集中與感測器缺失等情境。
- 泛化測試：以不同機櫃、不同日期或不同負載型態作為測試集，確認模型是否過度依賴特定機櫃。

6.3 實作路線圖：資料整備、模型訓練、部署與監控

1. 建立感測稽核工具，報告 Redfish、PDU、環境與機櫃中繼資料欄位在時間上的可用情況。
2. 使用已證實的功率、溫度、風扇、PDU 與機櫃中繼資料特徵，實作保守基準模型。
3. 訓練 XGBoost/LightGBM 模型進行伺服器層級與機櫃層級預測，並與簡單基準模型比較。
4. 加入空間特徵，例如機櫃區域、加權伺服器位置，以及鄰近熱/功率特徵。
5. 資料穩定後再加入時序模型、熱重建與數位孿生視覺化層。
6. 先將預測用於警告與建議；在任何閉迴路控制之前，先於數位孿生或具規則限制的模擬器中評估決策。

6.4 數位孿生與強化學習之未來擴充

數位孿生是一個整合監測、熱場重建、視覺化與策略評估的系統環境。在本報告中，數位孿生定位為未來擴充，用於安全地重播或模擬工作負載、冷卻變化與候選行動。強化學習不是 XGBoost/LightGBM 的替代品，而是可在數位孿生或模擬器中，根據已預測與重建的熱狀態選擇預防行動。實作時應先定義狀態、動作、獎勵與安全限制，並採用 shadow mode 逐步驗證。

6.5 開放議題：資料不足、模型泛化、可解釋性與安全性

- 資料不足：部分工作負載指標可能為 N/A，不能預設為可用。
- 模型泛化：模型可能只學到特定機櫃或特定時段的行為，需要跨機櫃與跨時間驗證。
- 可解釋性：預防建議應能指出主要風險來源，例如功率集中、溫度斜率或鄰近熱影響。
- 安全性：工作負載遷移、風扇控制與冷卻設定點變更，在自動化前必須先定義操作限制與回復規則。

7 結論

7.1 技術總結

本報告整理可支援資料中心熱監測、機櫃層級溫度預測與功率感知利用的 AI/ML 模型。XGBoost 與 LightGBM 適合作為 CortexDC 已驗證結構化感測資料的第一階段模型；GRU/LSTM 可在歷史資料穩定時處理熱延遲；U-Net/INR 可在空間資料足夠時進行熱場重建；數位孿生與強化學習則適合作為較後期的安全評估與決策最佳化層。

7.2 預期效益

預期效益包含較早偵測熱風險、降低 CPU/GPU 過熱機率、避免僅依賴靜態閾值的被動警報、改善機櫃功率利用率判斷，以及為未來工作負載調度與冷卻控制提供資料基礎。

7.3 未來發展方向

未來可朝三個方向擴充：第一，建立更完整的歷史感測資料集並驗證時序模型；第二，補足感測器座標與空間標籤以支援熱場重建；第三，建置數位孿生環境，在安全條件下評估強化學習或其他最佳化策略。

參考文獻

- [1] J. Lin, W. Lin, H. Huang, W. Lin, and K. Li, “Thermal modeling and thermal-aware energy saving methods for cloud data centers: A review,” IEEE Transactions on Sustainable Computing, vol. 9, no. 3, pp. 571–590, May–Jun. 2024.
- [2] K. Zhang et al., “Machine learning-based temperature prediction for runtime thermal management across system components,” IEEE Transactions on Parallel and Distributed Systems, vol. 29, no. 2, pp. 405–419, Feb. 2018.
- [3] K. Sano et al., “Improving accuracy of temperature distribution and energy-saving technology of air conditioners in data centers,” IEEE Transactions on Components, Packaging and Manufacturing Technology, vol. 8, no. 5, pp. 811–817, May 2018.
- [4] X. Wang et al., “Intelligent sensor placement for hot server detection in data centers,” IEEE Transactions on Parallel and Distributed Systems, vol. 24, no. 8, pp. 1577–1588, Aug. 2013.
- [5] S. Wang et al., “Data center temperature prediction and management based on a two-stage self-healing model,” Simulation Modelling Practice and Theory, vol. 132, Art. no. 102883, Apr. 2024.

- [6] H. Yuan et al., “An intelligent thermal management strategy for a data center prototype based on digital twin technology,” *Applied Sciences*, vol. 15, no. 14, Art. no. 7675, Jul. 2025.
- [7] T. R. Andersson et al., “Environmental sensor placement with convolutional Gaussian neural processes,” *Environmental Data Science*, vol. 2, Art. no. e32, 2023.
- [8] I. Nisce, X. Jiang, and S. P. Vishnu, “Machine learning based thermal prediction for energy-efficient cloud computing,” *Proc. IEEE CCNC*, 2023, pp. 624–627.
- [9] S. Ilager, K. Ramamohanarao, and R. Buyya, “Thermal prediction for efficient energy management of clouds using machine learning,” *IEEE Transactions on Parallel and Distributed Systems*, vol. 32, no. 5, pp. 1044–1056, May 2021.
- [10] J. Lin et al., “Thermal prediction for air-cooled data center using data driven-based model,” *Applied Thermal Engineering*, vol. 217, Art. no. 119207, Nov. 2022.
- [11] S. S. Gill et al., “ThermoSim: Deep learning based framework for modeling and simulation of thermal-aware resource management for cloud computing environments,” *Journal of Systems and Software*, vol. 166, Art. no. 110596, Aug. 2020.
- [12] S. Sabathiel et al., “Neural network-based reconstruction of steady-state temperature systems with unknown material composition,” *Scientific Reports*, vol. 14, Art. no. 22265, Sep. 2024.
- [13] X. Peng et al., “A deep learning method based on partition modeling for reconstructing temperature field,” *International Journal of Thermal Sciences*, vol. 182, Art. no. 107802, Dec. 2022.
- [14] X. Luo et al., “Continuous field reconstruction from sparse observations with implicit neural networks,” *Proc. ICLR*, 2024.
- [15] M. Zapater et al., “Leakage-aware cooling management for improving server energy efficiency,” *IEEE Transactions on Parallel and Distributed Systems*, vol. 26, no. 10, pp. 2764–2777, Oct. 2015.
- [16] C. S. Chan et al., “Optimal performance-aware cooling on enterprise servers,” *IEEE Transactions on Computer-Aided Design of Integrated Circuits and Systems*, vol. 38, no. 9, pp. 1689–1702, Sep. 2019.
- [17] Y. Ran et al., “DeepEE: Joint optimization of job scheduling and cooling control for data center energy efficiency using deep reinforcement learning,” *Proc. IEEE ICDCS*, 2019, pp. 645–655.
- [18] CortexDC, “CortexDC server Redfish monitoring data reference,” internal technical reference, 2026.
- [19] CortexDC, “CortexDC PDU monitoring data and communication protocol reference,” internal technical reference, 2026.
- [20] CortexDC Management System, “CortexDC data center inventory and rack infrastructure documentation,” internal technical report, May 21, 2026.